

Bayesowska analiza luki płciowej w osiągnięciach matematycznych na podstawie badania PISA 2022

1. Opis problemu

Celem projektu jest sprawdzenie, czy płeć ucznia wnosi dodatkową informację o wyniku z matematyki w badaniu PISA 2022. Nie porównujemy jednak dziewcząt i chłopców wyłącznie na podstawie samej płci. Wynik z matematyki może zależeć również od sytuacji rodzinnej, warunków pracy na lekcji oraz indywidualnej postawy ucznia wobec nauki.

Dlatego projekt został oparty na dwóch modelach.

Pierwszy model jest modelem bazowym i nie zawiera predyktora płci. Opisuje wynik z matematyki za pomocą trzech zmiennych z różnych kategorii: statusu społeczno-ekonomicznego, klimatu dyscyplinarnego na lekcjach matematyki oraz wytrwałości ucznia.

Drugi model rozszerza model bazowy o predyktor płci. Dzięki temu można sprawdzić, czy płeć poprawia wyjaśnianie wyników po uwzględnieniu innych czynników.

2. Teza

Uczniowie uzyskują lepsze wyniki w zakresie umiejętności matematycznych w badaniu PISA niż uczennice, nawet po uwzględnieniu różnic w statusie społeczno-ekonomicznym, klimacie dyscyplinarnym oraz wytrwałości

3. Źródło danych i zakres analizy

Źródłem danych jest *Programme for International Student Assessment 2022 (PISA 2022)*. Analiza została ograniczona do uczniów z Polski, aby uniknąć konieczności modelowania różnic między krajami.

4. Predyktory

Zmienną zależną jest wynik z matematyki w skali PISA, oznaczony jako y .

Predyktory w modelu bazowym dobrano tak, aby nie powielają tej samej informacji.

Zmienna	Kategoria	Znaczenie	Zakres wartości przed standaryzacją	Zakres wartości po standaryzacji	Rola w modelu
y	wynik ucznia	wynik z matematyki w skali PISA	0–1000 punktów	bez przekształcenia, zostaje w punktach PISA	zmienna zależna
ESCS	dom / rodzina	status ekonomiczno-społeczno-kulturowy ucznia	wartości ciągłe, np. ujemne i dodatnie względem średniej	standaryzacja: średnia = 0, odchylenie	kontrola wpływu zaplecza rodzinnego

				standardowe = 1	
DISCLIM	szkoła / lekcja	klimat dyscyplinarny na lekcjach matematyki	wartości ciągłe, niższe oznaczają gorszy klimat, wyższe lepszy klimat	standaryzacja: średnia = 0, odchylenie standardowe = 1	kontrola warunków pracy na lekcji
PERSEVAGR	cecha charakteru	wytrwałość ucznia w wykonywaniu zadań	wartości ciągłe, niższe oznaczają mniejszą wytrwałość, wyższe większą wytrwałość	standaryzacja: średnia = 0, odchylenie standardowe = 1	kontrola postawy ucznia wobec trudności
female	płeć	0 - chłopiec, 1 - dziewczynka	0 lub 1	bez przekształcenia, zostaje jako zmienna binarna 0/1	dodawana wyłącznie w Modelu 2

Standaryzacja predyktorów odbywa się zgodnie z poniższym wzorem.

$$X_z = \frac{X - \text{średnia}(X)}{sd(X)}$$

5. Parametry modelu

Parametr	Znaczenie
α	przewidywany średni wynik z matematyki dla ucznia o przeciętnych wartościach predyktorów bazowych
β_1	efekt statusu społeczno-ekonomicznego ESCS
β_2	efekt klimatu dyscyplinarnego DISCLIM
β_3	efekt wytrwałości ucznia PERSEVAGR
γ	efekt płci; różnica wyniku dziewcząt względem chłopców po kontroli pozostałych predyktorów
σ	odchylenie standardowe wyników wokół wartości przewidywanej przez model

6. Model 1 - model bazowy bez płci

$$y_i \sim \text{Normal}(\mu_i, \sigma)$$

$$\mu_i = \alpha + \beta_1 \cdot \text{ESCS}_i + \beta_2 \cdot \text{DISCLIM}_i + \beta_3 \cdot \text{PERSEVAGR}_i$$

Przewidywany wynik ucznia zależy od statusu społeczno-ekonomicznego, klimatu lekcji matematyki oraz wytrwałości ucznia. Na tym etapie nie sprawdzamy jeszcze wpływu płci.

7. Model 2 - model rozszerzony o płeć

$$y_i \sim \text{Normal}(\mu_i, \sigma)$$

$$\mu_i = \alpha + \beta_1 \cdot \text{ESCS}_i + \beta_2 \cdot \text{DISCLIM}_i + \beta_3 \cdot \text{PERSEVAGR}_i + \gamma \cdot \text{female}_i$$

$$\text{female}_i = 0 \text{ dla chłopców, } 1 \text{ dla dziewcząt}$$

W tym modelu parametr γ oznacza różnicę między dziewczętami i chłopcami przy takich samych wartościach ESCS, DISCLIM i PERSEVAGR. Dzięki temu płeć nie jest analizowana w oderwaniu od innych czynników, lecz jako dodatkowy predyktor ponad model bazowy.

8. Rozkłady a priori

$$\alpha \sim \text{Normal}(500, 50)$$

Średnia 500 odpowiada centralnej wartości skali PISA. Odchylenie standardowe 50 dopuszcza szeroki zakres możliwych średnich wyników dla uczniów w Polsce.

$$\beta_1, \beta_2, \beta_3 \sim \text{Normal}(0, 30)$$

Średnia 0 oznacza brak założonego z góry dodatniego lub ujemnego efektu predyktorów. Odchylenie standardowe 30 oznacza, że przed analizą dopuszczamy umiarkowane efekty, ale nie zakładamy skrajnie dużych zmian wyniku.

$$\gamma \sim \text{Normal}(0, 30)$$

Prior dla parametru płci γ jest neutralny. Średnia 0 oznacza, że przed analizą nie zakładamy przewagi żadnej płci. Odchylenie standardowe 30 oznacza, że ewentualna różnica między dziewczętami i chłopcami jest możliwa, ale bardzo duże różnice są uznawane za mniej prawdopodobne.

$$\sigma \sim \text{Exponential}(0.01)$$

Rozkład wykładniczy dla σ zapewnia dodatnie wartości odchylenia standardowego. Wartość oczekiwana tego rozkładu wynosi 100, co jest zgodne ze skalą wyników PISA.

